



PUC-SP



HELIPOINT DETECTOR

**Deteção de Helipontos em Telhados com Visão Computacional, Imagens de
Satélite e YOLO**

Professor

Rooney Ribeiro Albuquerque Coelho

Autores

Carlos Antonio Roth Gorham

Fabiana ⚡ Campanari

Pedro Vycor Almeida

Disciplina

Aprendizado de Máquina e Visão Computacional

Local

São Paulo – SP

Ano

2026

ÍNDICE

1. Resumo Executivo
2. Introdução
3. Definição do Problema
4. Objetivos
5. Contexto e Antecedentes
6. Arquitetura da Solução
7. Pipeline de Dados
8. Arquitetura de Backend
9. APIs e Integrações
10. Componentes de Inteligência Artificial
11. Camada de Dashboard e Analytics
12. Chatbot e IA Conversacional
13. Segurança
14. Governança e IA Responsável
15. Escalabilidade e Performance
16. Métricas de Destaque
17. Gráficos Gerados
18. Análise Qualitativa
19. Limitações
20. Melhorias Futuras
21. Resultados e Principais Desfechos
22. Análise de Dados e Insights
23. Apoio à Decisão e Recomendações
24. Conclusão
25. Próximos Passos

HELIPPOINT DETECTOR

Análise Completa do Projeto

1. Resumo Executivo

O projeto Helipoint Detector consiste em uma solução de visão computacional desenvolvida para detectar helipontos em telhados da cidade de São Paulo a partir de imagens de satélite de alta resolução. Trata-se de um sistema construído de ponta a ponta, cobrindo desde a coleta e preparação dos dados até o treinamento, avaliação e análise final do modelo.

O valor do projeto não está apenas no modelo treinado, mas principalmente na construção de um pipeline estruturado capaz de transformar coordenadas geográficas brutas em um dataset anotado e reutilizável. Dessa forma, o trabalho demonstra não apenas capacidade de modelagem, mas também domínio sobre engenharia de dados, curadoria de imagens, padronização de anotações e avaliação de desempenho.

O modelo final apresentou resultados muito fortes, especialmente considerando o tamanho reduzido do conjunto de treino. Na melhor época observada, a época 54, o detector alcançou precision 1.000, recall 0.963, mAP@50 0.994 e mAP@50–95 0.881; já na época final, a 60, manteve mAP@50 em 0.994, com precision 0.992, recall 0.971 e mAP@50–95 0.841, confirmando alto nível de precisão e forte

2. Introdução

A detecção automática de objetos em imagens aéreas e de satélite representa uma aplicação importante da visão computacional, especialmente em cenários urbanos complexos. No caso deste projeto, o foco está na identificação de helipontos instalados em coberturas de edifícios, estruturas que possuem relevância operacional e urbana, mas cuja detecção manual em larga escala seria lenta e de difícil manutenção.

O Helipoint Detector foi concebido como um projeto acadêmico aplicado, com o propósito de demonstrar o ciclo completo de desenvolvimento de uma solução de inteligência artificial voltada para imagens geoespaciais. Assim, o projeto vai além do simples treinamento de um

modelo e abrange todas as etapas necessárias para transformar um problema real em um pipeline técnico funcional.

Além disso, a tarefa apresenta dificuldade visual considerável. Helipontos podem variar em formato, cor, desgaste da pintura, contraste com o fundo, incidência de sombra e grau de oclusão. Em muitos casos, padrões presentes em piscinas, quadras, terraços ou outras estruturas urbanas podem ser confundidos com a marcação característica de um heliponto, o que torna o problema especialmente interessante do ponto de vista de classificação e detecção.

3. Definição do Problema

O problema central deste trabalho consiste em detectar automaticamente helipontos em telhados por meio de imagens de satélite obtidas de fontes públicas e processadas com técnicas de visão computacional. Em uma metrópole como São Paulo, essa tarefa é desafiadora devido à grande densidade urbana, à diversidade arquitetônica e à presença de múltiplos padrões visuais semelhantes.

Do ponto de vista técnico, o desafio não se limita ao reconhecimento visual da letra “H” ou da geometria típica dos helipontos. Também é necessário lidar com variações de escala, orientação, iluminação, sombra, baixa resolução local, ruído visual e sobreposição de elementos urbanos. Esses fatores aumentam a probabilidade de falsos positivos e falsos negativos, exigindo um dataset bem construído e um modelo robusto.

Resolver esse problema significa transformar imagens não estruturadas em informação geoespacial estruturada. Isso pode apoiar aplicações futuras em mapeamento urbano, monitoramento de infraestrutura, apoio à navegação aérea, estudos logísticos e inspeções visuais automatizadas.

4. Objetivos

O objetivo geral do projeto é desenvolver um sistema completo de detecção de helipontos em imagens de satélite, utilizando uma abordagem baseada em redes neurais convolucionais e modelos da família YOLO.

Entre os objetivos específicos, destacam-se:

- Construir um dataset original de helipontos em São Paulo.
- Coletar e organizar coordenadas geográficas dos alvos.
- Obter imagens de satélite de alta resolução.
- Realizar a anotação manual dos objetos.
- Treinar um modelo de detecção de objetos.
- Avaliar o modelo por meio de métricas quantitativas e análise qualitativa.
- Verificar a capacidade de generalização do sistema em áreas não vistas no treinamento.

O projeto também tem como objetivo demonstrar que a criação criteriosa dos dados é um dos principais fatores de sucesso em inteligência artificial aplicada. Nesse sentido, o trabalho funciona simultaneamente como experimento técnico, estudo de caso acadêmico e portfólio prático de engenharia de IA.

5. Contexto e Antecedentes

Este projeto está inserido no contexto da visão computacional aplicada a imagens geoespaciais urbanas. O uso de dados orbitais ou aéreos para detectar estruturas específicas é uma linha relevante de pesquisa e aplicação prática, principalmente em cidades de grande porte, onde o monitoramento visual manual é custoso e pouco escalável.

No ambiente acadêmico em que o trabalho foi desenvolvido, havia a exigência de construir um dataset original, documentar o pipeline e demonstrar treinamento e validação do modelo. Isso direcionou o projeto para uma abordagem fortemente orientada à reprodutibilidade, à organização de artefatos e à separação clara entre descoberta dos dados, preparação, anotação, treinamento e análise.

Do ponto de vista tecnológico, o projeto se apoia em ferramentas como FlightMarket, Selenium, ESRI World Imagery, Roboflow, notebooks Jupyter, Google Colab, Ultralytics YOLO e PyTorch. Essa combinação permitiu estruturar um fluxo técnico acessível, porém suficientemente robusto para gerar resultados consistentes.

6. Arquitetura da Solução

A arquitetura da solução foi organizada em módulos, de forma a permitir clareza metodológica e repetibilidade do processo. O fluxo parte da descoberta dos helipontos e suas coordenadas, passa pela aquisição das imagens, pela preparação do dataset, pela anotação dos objetos, pelo treinamento do modelo e chega à etapa de avaliação e inferência.

Essa organização modular é importante porque separa responsabilidades e facilita a evolução do projeto. Em vez de concentrar toda a lógica em um único script, o sistema foi pensado como uma sequência de componentes complementares, cada um responsável por uma etapa específica do ciclo de vida da solução.

Do ponto de vista conceitual, a arquitetura pode ser resumida em sete camadas: descoberta geoespacial, coleta de imagens, tratamento dos dados, anotação, treinamento, avaliação e apresentação dos resultados. Essa estrutura oferece boa base para futuras extensões, inclusive para aplicações web e fluxos mais próximos de MLOps.

7. Pipeline de Dados

O pipeline de dados inicia-se na coleta das coordenadas dos helipontos, obtidas a partir de fontes externas de registro e consulta. Essas coordenadas são organizadas em arquivos estruturados e depois convertidas em regiões geográficas de interesse.

A partir dessas regiões, são baixadas imagens de satélite em formato tile, posteriormente organizadas por bairro, recortadas, montadas e filtradas. Essa etapa é fundamental, pois define a qualidade visual da base de treino e influencia diretamente o desempenho final do detector.

Depois da aquisição das imagens, ocorre a curadoria manual do material, removendo exemplos inadequados e selecionando os recortes mais úteis. Em seguida, as imagens são anotadas com bounding boxes, redimensionadas para o formato de treino, submetidas a aumentos de dados e divididas em conjuntos de treino, validação e teste.

Esse pipeline mostra que o projeto não depende apenas do modelo, mas de uma cadeia de processamento bem definida. A qualidade do detector é consequência direta da qualidade do fluxo de dados.

8. Arquitetura de Backend

Embora o projeto não possua um backend tradicional baseado em microsserviços, ele apresenta uma arquitetura funcional centrada em scripts, notebooks e arquivos intermediários. Essa abordagem é adequada ao escopo acadêmico, pois privilegia simplicidade, rastreabilidade e facilidade de experimentação.

Os principais componentes dessa camada incluem scripts para coleta de coordenadas, transformação geográfica, obtenção de imagens, análise exploratória, treinamento do modelo e execução de inferência. Cada parte do fluxo gera artefatos específicos, que são armazenados em diretórios organizados para posterior inspeção.

Trata-se, portanto, de um backend orientado a processamento em lote e geração de artefatos, e não a serviços online permanentes. Ainda assim, essa estrutura é suficiente para demonstrar o pipeline completo com coerência técnica.

9. APIs e Integrações

O projeto utiliza diferentes fontes e plataformas externas para compor sua cadeia de processamento. Entre elas, destacam-se os serviços de imagens de satélite, as plataformas de anotação e os frameworks de treinamento.

A integração ocorre principalmente por troca de arquivos, consultas automatizadas, exportações e importações de datasets, e não por uma arquitetura complexa de APIs internas. Esse desenho é coerente com o objetivo do trabalho, que é demonstrar o ciclo técnico da solução sem aumentar desnecessariamente a complexidade de implantação.

Mesmo assim, a experiência mostra como dados provenientes de diferentes origens podem ser combinados em um fluxo unificado. Essa integração entre fontes externas e ferramentas especializadas é um dos aspectos mais importantes do projeto.

10. Componentes de Inteligência Artificial

O núcleo de inteligência artificial do projeto é um detector de objetos de classe única, treinado para localizar helipontos em imagens de satélite. A abordagem escolhida baseia-se na família

YOLO, reconhecida pelo bom equilíbrio entre velocidade e desempenho em tarefas de detecção.

O uso do YOLO é adequado porque o problema exige não apenas classificar a presença do objeto, mas também localizar sua posição exata na imagem por meio de bounding boxes. Para isso, o treinamento foi realizado com dados preparados no padrão YOLO, incluindo imagens e arquivos de rótulo correspondentes.

Além da escolha da arquitetura, o projeto também contempla avaliação de métricas clássicas de detecção, como precision, recall, mAP@50 e mAP@50–95. Isso permite uma análise mais rigorosa do comportamento do modelo e de sua qualidade espacial.

11. Camada de Dashboard e Analytics

A camada analítica do projeto está baseada principalmente em notebooks e artefatos gerados durante o treinamento. Não há um dashboard corporativo formal, mas existe uma estrutura suficiente para inspecionar métricas, gráficos e saídas visuais do modelo.

As análises incluem curvas de loss, evolução de precision e recall, curvas de mAP e inspeção qualitativa das predições. Esse material permite compreender tanto a dinâmica de aprendizado do modelo quanto seus acertos e limitações em casos concretos.

Embora essa abordagem seja mais artesanal do que um painel executivo tradicional, ela cumpre bem o papel de apoiar a interpretação técnica dos resultados. Em trabalhos acadêmicos, esse tipo de camada analítica costuma ser suficiente para demonstrar maturidade metodológica.

12. Chatbot e IA Conversacional

O projeto não implementa um chatbot nem um sistema de IA conversacional. Seu foco está inteiramente na visão computacional e na detecção de objetos em imagens geoespaciais.

Ainda assim, em uma evolução futura, seria possível adicionar uma interface conversacional para apoiar usuários na interpretação dos resultados. Um agente conversacional poderia, por exemplo, explicar o nível de confiança de uma detecção, resumir métricas ou auxiliar no processo de revisão humana das imagens.

No estado atual, porém, essa funcionalidade não faz parte do escopo do Helipoint Detector e não interfere nos resultados apresentados.

13. Segurança

Por se tratar de um projeto acadêmico e experimental, a solução não apresenta uma arquitetura completa de segurança corporativa. No entanto, existem preocupações implícitas relacionadas ao uso de plataformas externas, credenciais locais, ambientes de notebook e compartilhamento de artefatos.

Em projetos dessa natureza, boas práticas incluem controle de dependências, cuidado com exposição de chaves de acesso, organização do repositório e revisão do conteúdo publicado. Embora não sejam o foco principal do trabalho, esses cuidados são importantes para garantir rastreabilidade e reduzir riscos operacionais.

Em uma eventual evolução para ambiente produtivo, seria recomendável incorporar varredura de segredos, controle de permissões, validação de dependências e mecanismos mais formais de integridade dos artefatos.

14. Governança e IA Responsável

O projeto demonstra preocupações importantes com governança ao estabelecer critérios de anotação, curadoria dos dados, separação entre treino e validação e teste em regiões não vistas. Essas decisões metodológicas ajudam a reduzir vieses ocultos e tornam os resultados mais confiáveis.

A presença de análise qualitativa também é relevante sob a ótica de IA responsável, pois impede que a avaliação fique restrita apenas às métricas numéricas. Observar onde o modelo acerta, onde falha e por que falha é fundamental para compreender seus limites reais.

Como melhoria futura, seria interessante formalizar ainda mais a linhagem do dataset, o rastreamento de experimentos e a documentação das versões do modelo. Isso aumentaria a capacidade de auditoria e comparação entre execuções.

15. Escalabilidade e Performance

A solução atual apresenta boa escalabilidade dentro do contexto acadêmico, principalmente porque automatiza etapas importantes da descoberta geoespacial e da preparação dos dados. Isso reduz trabalho manual e facilita a expansão do projeto para novos bairros ou conjuntos de imagens.

Entretanto, para um cenário produtivo mais amplo, seriam necessários mecanismos adicionais de orquestração, monitoramento, versionamento de modelos, controle de drift e gestão de experimentos. Em outras palavras, o projeto já possui uma base sólida, mas ainda precisaria de amadurecimento para operar como produto em larga escala.

No que se refere à performance, os principais gargalos potenciais estão na obtenção e preparação dos dados, no tempo de anotação humana e no custo computacional do treinamento. O uso de GPU no Colab contribuiu para tornar o processo mais viável.

16. Métricas de Destaque

Os resultados obtidos pelo modelo foram bastante expressivos, especialmente considerando o tamanho reduzido do dataset de treino. O melhor desempenho global ocorreu na época 54, enquanto a época final analisada foi a 60.


Esses números mostram que o modelo alcançou altíssimo nível de precisão e excelente desempenho geral de detecção. O fato de o mAP@50 permanecer em 0.994 tanto no melhor ponto quanto na época final indica forte estabilidade do detector no critério padrão. Já o mAP@50–95 reforça que as caixas delimitadoras também foram bem ajustadas sob um critério mais rigoroso.

Métrica	Melhor Época (54)	Época Final (60)
Precision	1.000	0.992
Recall	0.963	0.971
mAP@50	0.994	0.994
mAP@50–95	0.881	0.841

A leitura conjunta dessas métricas sugere que o modelo atingiu um ponto ótimo por volta da época 54, mantendo depois desempenho muito alto, mas com pequena redução no critério mais rigoroso de localização. Isso reforça a interpretação de que o treinamento foi bem-sucedido e de que a seleção da melhor época pode ser mais vantajosa do que simplesmente considerar a última.

17. Gráficos Gerados

Figura 1 — Evolução das Losses por Época




As curvas de loss indicam aprendizado consistente ao longo das 60 épocas. Tanto as perdas de treino quanto as de validação diminuem progressivamente, sugerindo que o modelo conseguiu aprender padrões úteis sem sinais evidentes de divergência entre os dois conjuntos.

Figura 2 — Precision e Recall ao Longo do Treino



As curvas de precision e recall mostram evolução rápida do desempenho e estabilização em níveis muito altos nas etapas finais do treinamento. Isso sugere que o modelo conseguiu equilibrar bem a detecção dos objetos verdadeiros com a redução de falsos positivos.

Figura 3 — mAP@50 e mAP@50-95



As curvas de mAP mostram desempenho excelente tanto no critério mais permissivo quanto no critério mais rigoroso. O pico na época 54 reforça a percepção de que esse foi o momento ótimo de treinamento para o dataset disponível.

18. Análise Qualitativa

A análise qualitativa é importante porque complementa as métricas numéricas com observação visual direta do comportamento do modelo. Em projetos de detecção de objetos, essa etapa é essencial para entender se o sistema erra por confusão geométrica, baixa visibilidade, ruído visual ou ambiguidade contextual.

Tipo	O que mostrar	O que explicar
Acerto claro	Heliponto detectado com caixa bem ajustada e confiança alta	Mostrar que o modelo reconhece com precisão o padrão clássico do objeto
Acerto desafiador	Heliponto parcialmente coberto ou em ângulo	Demonstrar robustez do detector em situações menos favoráveis
Falso positivo	Estrutura semelhante a heliponto	Explicar que certos padrões urbanos ainda geram confusão visual
Falso negativo	Heliponto não detectado	Evidenciar limites do modelo em casos de sombra, desgaste ou baixo contraste

19. Limitações

A principal limitação do projeto está no tamanho e no escopo geográfico do dataset. Embora a base tenha sido construída de forma original e criteriosa, ela ainda representa uma fração limitada da diversidade visual possível de helipontos urbanos.

Outra limitação importante diz respeito à maturidade arquitetural. O projeto foi bem estruturado para fins acadêmicos e de demonstração técnica, mas ainda não possui todos os mecanismos que seriam esperados em uma solução produtiva completa, como monitoramento contínuo, versionamento formal de modelos e governança operacional avançada.

Também existe limitação inerente à anotação humana e à ambiguidade visual. Certas estruturas urbanas podem ser suficientemente parecidas com helipontos para continuar gerando erros, mesmo em modelos bem treinados.

20. Melhorias Futuras

Entre as melhorias futuras, a primeira prioridade é expandir e diversificar o dataset. Incluir mais bairros, diferentes condições de iluminação, novas escalas e exemplos negativos mais variados tende a aumentar a robustez do detector.

Outra melhoria importante é formalizar o rastreamento de experimentos, permitindo comparar versões de modelo, parâmetros de treino e métricas de forma mais sistemática. Isso facilitaria tanto a análise acadêmica quanto a evolução técnica do sistema.

Também seria interessante aprimorar a interface de demonstração, incorporando upload em lote, filtros por confiança, revisão assistida e relatórios exportáveis. Em um estágio posterior, o projeto poderia evoluir para uma solução com práticas explícitas de MLOps.

21. Resultados e Principais Desfechos

O principal desfecho do projeto foi a construção de uma solução funcional de ponta a ponta para detecção de helipontos em imagens de satélite. Isso inclui coleta dos dados, criação do dataset, anotação, treinamento, avaliação e análise dos resultados.

Além disso, o projeto demonstrou que é possível atingir desempenho muito alto mesmo com uma base relativamente pequena, desde que a curadoria e a anotação dos dados sejam feitas com qualidade. Os resultados quantitativos — especialmente precision de 1.000 na melhor época, mAP@50 de 0.994 e recall final de 0.971 — reforçam esse ponto de vista metodológico.

Outro desfecho relevante foi a produção de um pipeline reutilizável. A estrutura criada pode servir como base para novos experimentos, expansão geográfica e adaptação para outros tipos de objetos urbanos.

22. Análise de Dados e Insights

Um dos principais insights do projeto é que a qualidade dos dados exerce influência determinante sobre o desempenho do modelo. Em outras palavras, o sucesso obtido não decorre apenas da escolha do YOLO, mas da construção cuidadosa do conjunto de treino.

Outro insight importante é que a generalização deve ser tratada como critério central de avaliação. Testar o modelo em áreas não vistas é essencial para verificar se ele realmente aprendeu padrões do objeto e não apenas características específicas do conjunto de treino.

Também se observa que os erros residuais do modelo tendem a se concentrar em situações visualmente ambíguas, enquanto as métricas agregadas permaneceram em nível muito alto ao final do treinamento. A diferença entre o melhor mAP@50–95, de 0.881 na época 54, e o valor final de 0.841 sugere que o desempenho máximo espacial

23. Apoio à Decisão e Recomendações

A principal recomendação decorrente deste trabalho é priorizar a evolução do pipeline de dados. Melhorias em curadoria, diversidade visual, controle de qualidade e critérios de anotação provavelmente terão impacto tão grande quanto, ou maior do que, mudanças na arquitetura do modelo.

Outra recomendação é manter o uso de métricas quantitativas combinado com análise qualitativa. Em projetos de visão computacional, a leitura exclusiva de indicadores numéricos pode esconder padrões de erro relevantes que só aparecem na inspeção visual.

Por fim, recomenda-se preservar a avaliação em bairros não vistos como prática permanente. Esse tipo de teste é um dos melhores indicadores de robustez do sistema em condições próximas ao uso real.

24. Conclusão

O Helipoint Detector cumpriu com sucesso seu objetivo de demonstrar a construção de uma solução completa de inteligência artificial voltada à detecção de helipontos em telhados. O trabalho evidenciou domínio sobre coleta de dados, engenharia geoespacial, curadoria de imagens, anotação, treinamento, avaliação e interpretação dos resultados.

Os resultados quantitativos confirmam que o modelo alcançou desempenho muito elevado, mesmo com uma base compacta. Isso reforça a importância da qualidade do dataset e valida a estratégia adotada ao longo do projeto.

De forma geral, o projeto apresenta valor acadêmico, técnico e prático. Ele funciona como uma prova concreta de que a combinação entre dados bem preparados, metodologia clara e avaliação rigorosa pode gerar soluções robustas mesmo em contextos desafiadores.

25. Próximos Passos

Os próximos passos mais naturais incluem ampliar o dataset, consolidar o acompanhamento de experimentos e fortalecer a estrutura de avaliação contínua. Essas medidas devem aumentar a robustez do modelo e facilitar comparações entre versões futuras.

Também é recomendável evoluir a camada de apresentação dos resultados, seja por meio de uma interface web mais completa, seja por meio de relatórios automáticos com visualizações e métricas padronizadas. Isso aumentaria o valor do projeto para demonstrações, apresentações e aplicações futuras.

No médio prazo, a solução pode evoluir para um sistema geoespacial mais amplo, capaz de identificar outros tipos de estruturas urbanas, mantendo a mesma base metodológica empregada neste trabalho. Em paralelo, a institucionalização de critérios de seleção do melhor checkpoint, como o observado na época 54, pode melhorar ainda mais a confiabilidade das versões futuras do detector