



Documentação do Projeto — Pipeline Completo, Metodologia e Resultados

**Pontifícia Universidade Católica de São Paulo (PUC-SP) — FACEI
Graduação em Human Centered-AI & Data Science
AI / ML - Computer Vision — Projeto P2**

Professor: Rooney Ribeiro Albuquerque Coelho

Autores:

Carlos Antonio dos Santos Roth Gorham ·
Fabiana Campanari
Pedro Vyctor Almeida

São Paulo -2026

Sumário

1. Sumário
2. Definição do Projeto
3. Objetivo
4. Por que Helipontos / Fonte de Dados
5. **Pipeline Técnico Completo** — as 12 etapas, numeradas, do scraping até a validação de campo
6. Coleta de Imagens e Anotação
7. Modelagem com YOLO (incluindo a nota sobre o bug de integridade de dados exp2/exp3 que vocês corrigiram)
8. Avaliação Quantitativa (tabela exp1/exp2/exp3)
9. Validação de Campo (tabela completa dos 10 bairros)
10. Análise Qualitativa (tabela de casos reais)
11. Aplicação Web (as 9 abas do dashboard)
12. Pontos Fortes / Limitações / Melhorias Futuras
13. Ética, LGPD e Governança
14. Conclusão

1. Sumário

Sumário	2
1. Sumário	2

2. Definição do Projeto

6

O Helipoint Detector implementa um pipeline completo de Detecção de Objetos para identificar helipontos em telhados na cidade de São Paulo, usando imagens aéreas/orbitais de alta resolução e modelos da família YOLOv8/YOLOv11. O projeto cobre todo o ciclo de vida de um sistema aplicado de visão computacional: coleta programática de imagens, automação geoespacial, criação e curadoria de dataset, anotação, pré-processamento, treinamento, avaliação quantitativa e qualitativa, inferência em bairros não vistos, uma etapa de validação de campo em dados reais em dez bairros, e uma camada de aplicação web interativa. Em vez de depender de um benchmark pronto, o projeto constrói um dataset original do zero e o valida com experimentos reproduzíveis.

6

3. Objetivo

6

O objetivo principal é construir um sistema de ponta a ponta capaz de detectar helipontos em telhados em São Paulo, cobrindo: aquisição programática de dados de satélite; curadoria visual e filtragem de tiles; anotação com bounding boxes; pré-processamento e aumento; treinamento e monitoramento; avaliação quantitativa e análise qualitativa de erros; inferência em um bairro totalmente não visto; e — além do escopo mínimo do briefing do curso — uma validação de campo em dados reais, sobre milhares de tiles sem curadoria prévia, em dez bairros.

6

4. Por que Helipontos, e Fonte de Dados

6

Helipontos são um alvo interessante: apresentam um padrão geométrico distintivo visto de cima (um "H" no telhado), mas ainda são genuinamente difíceis de detectar, pois podem ser confundidos com estruturas de telhado, marcações esportivas ou superfícies reflexivas — bom material para discutir falsos positivos e generalização. O escopo geográfico segue o briefing: a cidade de São Paulo, com foco em bairros próximos a corredores corporativos densos (Perdizes, Higienópolis, Pacaembu, Sumaré, Av. Paulista, Itaim Bibi, Pinheiros, Faria Lima, Berrini, Vila Olímpia, Brooklin e Morumbi). A fonte primária de imagens é o ESRI World Imagery (tiles XYZ), com atribuição obrigatória: "Source: Esri, Maxar, Earthstar Geographics, and the GIS User Community".

6

5. Pipeline Técnico Completo

6

1. Descobrir registros de helipontos em um site de aviação (src/geospatial/helipad_bot.py, automação Selenium). 6
2. Extrair coordenadas e metadados de localização de cada registro. 6
3. Salvar e organizar os dados em src/geospatial/helipad_coordinates.csv. 7
4. Converter coordenadas em bounding boxes geográficas (src/geospatial/transform_coordinates.py). 7
5. Baixar tiles de satélite do ESRI World Imagery para cada bounding box (zoom 19). 7
6. Construir mosaicos por bairro ou região (src/geospatial/geospatial_image_collection.ipynb). 7
7. Fazer triagem manual dos mosaicos, mantendo só imagens com helipontos claros. 7
8. Enviar imagens selecionadas ao Roboflow e anotar com bounding boxes de classe única e bem ajustadas. 7
9. Gerar versões do dataset (resize 640×640, splits, augmentations) e exportar em formato YOLO. 7

10. Treinar modelos YOLOv8n no Google Colab (GPU T4), monitorando métricas e curvas.	7
11. Rodar inferência em um bairro não visto e analisar resultados quantitativa e qualitativamente.	7
12. Rodar uma validação de campo em dados reais: baixar e inferir em 10 bairros completos (7.943 tiles), muito além de imagens curadas de benchmark.	7
6. Coleta de Imagens e Anotação	7
A coleta programática segue o padrão de tiles XYZ do ESRI World Imagery: zoom 19 para alvos pequenos como helipontos, bounding boxes definidas por bairro, convertidas em índices de tile via uma função <code>deg2tile</code> , baixadas com filtragem de status HTTP/placeholders, e organizadas por bairro e zoom. O Google Earth Web foi usado só como fonte complementar para capturas pontuais, nunca para coleta em massa.	7
A anotação foi feita no Roboflow: upload de imagens curadas, desenho de bounding boxes bem ajustadas e de classe única ("heliponto"), critérios escritos para visibilidade parcial/sombras/reflexos, <code>resize</code> para 640×640, <code>augmentations</code> (rotações de 90°, <code>flips</code> , mudanças de brilho/contraste), e <code>split</code> em 70% treino / 20% validação / 10% teste. O trabalho de anotação foi compartilhado entre a equipe, não concentrado em uma única pessoa.	7
7. Modelagem com YOLO	8
O treinamento usou Ultralytics YOLOv8n no Google Colab (GPU T4), Python, PyTorch e a biblioteca roboflow para integração do dataset. Conforme o briefing, pelo menos dois experimentos foram rodados, variando um hiperparâmetro por vez:	8
8. Avaliação Quantitativa — Resultados de Treinamento	8
Os três experimentos são descobertos automaticamente e comparados ao vivo no dashboard Streamlit do projeto (aba Experiment Metrics). Métricas principais:	8
O exp2 supera levemente o exp1 em <code>mAP@50-95</code> (+0,0065) com 100 épocas, enquanto o exp1 permanece marginalmente à frente em <code>Precision</code> na sua melhor época — ambos dentro da margem de ruído esperada dado o tamanho pequeno do dataset (~150 imagens). As curvas de <code>loss</code> não mostram <code>overfitting</code> : a <code>loss</code> de validação acompanha de perto a <code>loss</code> de treino em todas as execuções.	8
9. Validação de Campo — Detecção em Dados Reais em 10 Bairros de São Paulo	8
Além das imagens curadas de treino/validação/teste, o melhor modelo (exp2) foi rodado contra 7.943 tiles reais de satélite, cobrindo 10 bairros de São Paulo — corredores corporativos densos como Itaim Bibi, Av. Paulista, Vila Olímpia, Pinheiros, Brooklin e Faria Lima. Os tiles e bounding boxes por região vêm de <code>src/geospatial/sp_neighborhoods_bbox.csv</code> ; o download de tiles e a inferência são automatizados por <code>src/geospatial/download_all_regions.py</code> e <code>auto_triage_regions.py</code> , ambos retomáveis, permitindo pausar e continuar sem reprocessar o que já foi feito.	8
Inter-Zone Corridor e Itaim Bibi apresentam as maiores taxas de detecção, coerente com serem corredores corporativos densos. Alphaville Industrial — perfil mais industrial — apresenta a menor taxa, alinhado ao esperado para esse tipo de uso do solo.	9
10. Análise Qualitativa	9
Em linha com o briefing, tanto as imagens curadas de teste quanto a rodada de validação de campo do Faria Lima foram revisadas caso a caso:	9

Os falsos positivos seguem um padrão esperado e explicável: piscinas e quadras esportivas compartilham geometria/contraste retangular com o "H" do heliponto. O problema dos tiles vazios é uma lacuna do pipeline de dados, não um erro do modelo — uma correção recomendada (checar o desvio-padrão de pixel antes da inferência) está documentada para uma próxima iteração.	10
11. Aplicação Web Interativa	10
apps/streamlit_app/app.py implementa um dashboard Streamlit completo com 9 abas, indo além do requisito opcional do briefing de uma interface de demonstração simples:	10
12. Pontos Fortes, Limitações e Melhorias Futuras	10
13. Ética, LGPD e Governança	11
O projeto segue práticas-chave de IA responsável: uso apenas de imagens de satélite de área pública; nenhuma anotação de pessoas, placas de veículo ou outros identificadores pessoais; IA generativa usada apenas como ferramenta de apoio documentada; e foco acadêmico/de pesquisa, sem intenção de vigilância individual. Na perspectiva da LGPD, o projeto minimiza dados pessoais identificáveis, documenta as fontes de imagem e sua atribuição (Esri, Maxar, Earthstar Geographics e a GIS User Community), e restringe o uso dos resultados a fins acadêmicos e de pesquisa.	11
14. Conclusão	11
O Helipoint Detector atinge métricas de nível profissional ($mAP@50 \approx 99\%$, $mAP@50-95 \approx 88\%$) em um dataset construído inteiramente do zero, e a etapa de validação de campo confirma que esses resultados se sustentam em cobertura real de satélite, sem curadoria, em dez bairros — com padrões de erro documentados e explicáveis, em vez de falhas opacas. Isso valida tanto o modelo em si quanto a ênfase mais ampla do projeto em qualidade de dado, governança de anotação, reprodutibilidade e documentação honesta e baseada em evidências.	11
Helipoint Detector · PUC-SP · Machine Learning / Visão Computacional · 2026	11

2. Definição do Projeto

O Helipoint Detector implementa um pipeline completo de Detecção de Objetos para identificar helipontos em telhados na cidade de São Paulo, usando imagens aéreas/orbitais de alta resolução e modelos da família YOLOv8/YOLOv11. O projeto cobre todo o ciclo de vida de um sistema aplicado de visão computacional: coleta programática de imagens, automação geoespacial, criação e curadoria de dataset, anotação, pré-processamento, treinamento, avaliação quantitativa e qualitativa, inferência em bairros não vistos, uma etapa de validação de campo em dados reais em dez bairros, e uma camada de aplicação web interativa. Em vez de depender de um benchmark pronto, o projeto constrói um dataset original do zero e o valida com experimentos reprodutíveis.

3. Objetivo

O objetivo principal é construir um sistema de ponta a ponta capaz de detectar helipontos em telhados em São Paulo, cobrindo: aquisição programática de dados de satélite; curadoria visual e filtragem de tiles; anotação com bounding boxes; pré-processamento e aumento; treinamento e monitoramento; avaliação quantitativa e análise qualitativa de erros; inferência em um bairro totalmente não visto; e — além do escopo mínimo do briefing do curso — uma validação de campo em dados reais, sobre milhares de tiles sem curadoria prévia, em dez bairros.

4. Por que Helipontos, e Fonte de Dados

Helipontos são um alvo interessante: apresentam um padrão geométrico distintivo visto de cima (um "H" no telhado), mas ainda são genuinamente difíceis de detectar, pois podem ser confundidos com estruturas de telhado, marcações esportivas ou superfícies reflexivas — bom material para discutir falsos positivos e generalização. O escopo geográfico segue o briefing: a cidade de São Paulo, com foco em bairros próximos a corredores corporativos densos (Perdizes, Higienópolis, Pacaembu, Sumaré, Av. Paulista, Itaim Bibi, Pinheiros, Faria Lima, Berrini, Vila Olímpia, Brooklin e Morumbi). A fonte primária de imagens é o ESRI World Imagery (tiles XYZ), com atribuição obrigatória: "Source: Esri, Maxar, Earthstar Geographics, and the GIS User Community".

5. Pipeline Técnico Completo

1. Descobrir registros de helipontos em um site de aviação (src/geospatial/helipad_bot.py, automação Selenium).
2. Extrair coordenadas e metadados de localização de cada registro.

3. Salvar e organizar os dados em `src/geospatial/helipad_coordinates.csv`.
4. Converter coordenadas em bounding boxes geográficas (`src/geospatial/transform_coordinates.py`).
5. Baixar tiles de satélite do ESRI World Imagery para cada bounding box (zoom 19).
6. Construir mosaicos por bairro ou região (`src/geospatial/geospatial_image_collection.ipynb`).
7. Fazer triagem manual dos mosaicos, mantendo só imagens com helipontos claros.
8. Enviar imagens selecionadas ao Roboflow e anotar com bounding boxes de classe única e bem ajustadas.
9. Gerar versões do dataset (resize 640×640, splits, augmentations) e exportar em formato YOLO.
10. Treinar modelos YOLOv8n no Google Colab (GPU T4), monitorando métricas e curvas.
11. Rodar inferência em um bairro não visto e analisar resultados quantitativa e qualitativamente.
12. Rodar uma validação de campo em dados reais: baixar e inferir em 10 bairros completos (7.943 tiles), muito além de imagens curadas de benchmark.

6. Coleta de Imagens e Anotação

A coleta programática segue o padrão de tiles XYZ do ESRI World Imagery: zoom 19 para alvos pequenos como helipontos, bounding boxes definidas por bairro, convertidas em índices de tile via uma função `deg2tile`, baixadas com filtragem de status HTTP/placeholders, e organizadas por bairro e zoom. O Google Earth Web foi usado só como fonte complementar para capturas pontuais, nunca para coleta em massa.

A anotação foi feita no Roboflow: upload de imagens curadas, desenho de bounding boxes bem ajustadas e de classe única ("heliponto"), critérios escritos para visibilidade parcial/sombras/reflexos, resize para 640×640, augmentations (rotações de 90°, flips, mudanças de brilho/contraste), e split em 70% treino / 20% validação / 10% teste. O trabalho de anotação foi compartilhado entre a equipe, não concentrado em uma única pessoa.

7. Modelagem com YOLO

O treinamento usou Ultralytics YOLOv8n no Google Colab (GPU T4), Python, PyTorch e a biblioteca roboflow para integração do dataset. Conforme o briefing, pelo menos dois experimentos foram rodados, variando um hiperparâmetro por vez:

- exp1 — dataset original, 60 épocas, imsz 640, batch 16, seed 42.
- exp2 — dataset original, 100 épocas (mesmo imsz/batch/seed), para testar se mais treino ajuda ou causa overfitting.
- exp3 — versão aumentada (fork) do dataset (rotação $\pm 15^\circ$, brilho 25%, flip H/V), 100 épocas, mantido como ponto de dado separado por usar uma versão diferente do dataset.

Um problema de integridade de dados foi encontrado e corrigido durante o projeto: uma execução inicial do notebook baixou silenciosamente o dataset com fork, mas salvou os resultados sob o nome "exp2", gerando documentação falsa. Isso foi corrigido renomeando essa execução para exp3 e re-rodando o exp2 contra o workspace correto (dataset original) — com um guard de assert agora presente no notebook de treino para impedir que esse tipo de erro silencioso aconteça de novo.

8. Avaliação Quantitativa — Resultados de Treinamento

Os três experimentos são descobertos automaticamente e comparados ao vivo no dashboard Streamlit do projeto (aba Experiment Metrics). Métricas principais:

Experimento	Melhor Época	Precision	Recall	mAP@50	mAP@50-95
exp1 (60 ép., original)	54	1.000	0.963	0.994	0.881
exp2 (100 ép., original)	81	0.982	0.971	0.993	0.888
exp3 (100 ép., fork aumentado)	78	0.943	1.000	0.993	0.885

O exp2 supera levemente o exp1 em mAP@50-95 (+0,0065) com 100 épocas, enquanto o exp1 permanece marginalmente à frente em Precision na sua melhor época — ambos dentro da margem de ruído esperada dado o tamanho pequeno do dataset (~150 imagens). As curvas de loss não mostram overfitting: a loss de validação acompanha de perto a loss de treino em todas as execuções.

9. Validação de Campo — Detecção em Dados Reais em 10 Bairros de São Paulo

Além das imagens curadas de treino/validação/teste, o melhor modelo (exp2) foi rodado contra 7.943 tiles reais de satélite, cobrindo 10 bairros de São Paulo — corredores corporativos densos como Itaim Bibi, Av. Paulista, Vila Olímpia, Pinheiros, Brooklin e

Faria Lima. Os tiles e bounding boxes por região vêm de `src/geospatial/sp_neighborhoods_bbox.csv`; o download de tiles e a inferência são automatizados por `src/geospatial/download_all_regions.py` e `auto_triage_regions.py`, ambos retomáveis, permitindo pausar e continuar sem reprocessar o que já foi feito.

Bairro	Detectados	Total de Tiles	Taxa
Inter-Zone Corridor	133	480	27,7%
Itaim Bibi	191	750	25,5%
Brooklin	231	1.014	22,8%
Vila Olímpia	158	660	23,9%
Av. Paulista (Trecho 1)	179	840	21,3%
Faria Lima	170	840	20,2%
Av. Paulista (Trecho 2)	157	780	20,1%
Pinheiros	244	1.232	19,8%
Vila Nova Conceição	109	572	19,1%
Alphaville Industrial	105	775	13,6%
TOTAL	1.677	7.943	21,1%

Inter-Zone Corridor e Itaim Bibi apresentam as maiores taxas de detecção, coerente com serem corredores corporativos densos. Alphaville Industrial — perfil mais industrial — apresenta a menor taxa, alinhado ao esperado para esse tipo de uso do solo.

10. Análise Qualitativa

Em linha com o briefing, tanto as imagens curadas de teste quanto a rodada de validação de campo do Faria Lima foram revisadas caso a caso:

Tipo	Tile de Exemplo	Confiança	Observação
Acerto claro	tile_z19_x194126_y297485.jpg	0.94	Padrão "H" nítido em quadrado bem definido no telhado
Acerto claro	tile_z19_x194143_y297481.jpg	0.96	Geometria e contraste claros, caixa bem ajustada
Acerto desafiador	tile_z19_x194545_y298183.jpg	0.77	Detecção correta mesmo com ângulo/iluminação menos favorável
Falso Positivo	tile_z19_x194129_y297480.jpg	0.78	Caixa sobre quadra esportiva, não heliponto
Falso Positivo	tile_z19_x194547_y298176.jpg	0.86	Caixa sobre piscina, geometricamente parecida com o "H"
Falha de dado (não do modelo)	tile_z19_x194139_y297467.jpg	—	Tile vazio/preto (falha de download ESRI) marcado como "Detected"

Os falsos positivos seguem um padrão esperado e explicável: piscinas e quadras esportivas compartilham geometria/contraste retangular com o "H" do heliponto. O problema dos tiles vazios é uma lacuna do pipeline de dados, não um erro do modelo — uma correção recomendada (checar o desvio-padrão de pixel antes da inferência) está documentada para uma próxima iteração.

11. Aplicação Web Interativa

`apps/streamlit_app/app.py` implementa um dashboard Streamlit completo com 9 abas, indo além do requisito opcional do briefing de uma interface de demonstração simples:

Aba	Finalidade
 Experiment Metrics	Descobre automaticamente cada experimento treinado, comparando Precision/Recall/mAP ao vivo
 Field Detections by Region	Cards, gráfico de barras e tabela da validação de campo em 10 bairros
 Map	Mapa Folium em modo escuro com 3 camadas alternáveis, incluindo uma camada de taxa de detecção em escala de azul
 Search by Region	Busca ao vivo por bounding box: baixa tiles e roda inferência sob demanda
 Sample Images	Detecções reais pré-selecionadas para demonstração instantânea
 Upload Image	Upload de qualquer imagem aérea/satélite para detecção anotada
 Pipeline	Passo a passo visual do pipeline completo de 12 etapas
 Governance	Declarações de justiça, LGPD e limitações conhecidas
 Downloads	Relatórios, dataset, métricas e artefatos da validação de campo

12. Pontos Fortes, Limitações e Melhorias Futuras

Pontos Fortes

Pontos fortes: cobertura de ponta a ponta do ciclo de vida do projeto de CV; foco explícito em engenharia de dados, não só em modelagem; automação geoespacial aumentando escala e reprodutibilidade; uma etapa de validação de campo em dados reais além dos benchmarks curados; uma camada de aplicação interativa completa.

Limitações

Limitações: confusão visual com piscinas/quadras esportivas continua sendo a principal fonte de falsos positivos; resultados dependem da consistência de anotação entre os membros da equipe; a generalização é limitada pela diversidade de padrões de telhado vistos no treino.

Melhorias Futuras

- Adicionar mais exemplos negativos (piscinas, quadras esportivas) para reduzir falsos positivos.
- Adicionar um filtro automático de tile vazio antes da inferência no pipeline de validação de campo.
- Estender a validação de campo para outros bairros e para a região totalmente não vista da Baixada Santista.
- Comparar sistematicamente YOLOv8n vs. YOLOv11n nos mesmos splits de dataset.

13. Ética, LGPD e Governança

O projeto segue práticas-chave de IA responsável: uso apenas de imagens de satélite de área pública; nenhuma anotação de pessoas, placas de veículo ou outros identificadores pessoais; IA generativa usada apenas como ferramenta de apoio documentada; e foco acadêmico/de pesquisa, sem intenção de vigilância individual. Na perspectiva da LGPD, o projeto minimiza dados pessoais identificáveis, documenta as fontes de imagem e sua atribuição (Esri, Maxar, Earthstar Geographics e a GIS User Community), e restringe o uso dos resultados a fins acadêmicos e de pesquisa.

14. Conclusão

O Helipoint Detector atinge métricas de nível profissional ($mAP@50 \approx 99\%$, $mAP@50-95 \approx 88\%$) em um dataset construído inteiramente do zero, e a etapa de validação de campo confirma que esses resultados se sustentam em cobertura real de satélite, sem curadoria, em dez bairros — com padrões de erro documentados e explicáveis, em vez de falhas opacas. Isso valida tanto o modelo em si quanto a ênfase mais ampla do projeto em qualidade de dado, governança de anotação, reprodutibilidade e documentação honesta e baseada em evidências.