

Pontifícia Universidade Católica de São Paulo
Programa de Estudos Pós-Graduados em
Tecnologias da Inteligência e Design Digital (TIDD)
Fabiana Rotella Campaner

Avaliação de detectores visuais sem verdade de campo

Linhagem de dados e revisão humana na detecção de helipontos em imagens de satélite de São Paulo

Pré-projeto de pesquisa
Processo Seletivo 1º/2027, Mestrado
São Paulo
2026

Sumário

RESUMO 3
1 QUESTÃO DA PESQUISA 3
1.1 Contexto e problema 3
1.2 Pergunta central e perguntas derivadas 5
2 ESTADO DA ARTE 6
3 JUSTIFICATIVAS 7
4 OBJETIVOS 7
5 HIPÓTESES 8
6 FUNDAMENTAÇÃO TEÓRICA 8
6.1 Evidência quando não há verdade de campo 8
7 METODOLOGIA 9
8 CRONOGRAMA 11
BIBLIOGRAFIA PRELIMINAR 12

Avaliação de detectores visuais sem verdade de campo

Linhagem de dados e revisão humana na detecção de helipontos em imagens de satélite de São Paulo

Documento: pré-projeto de pesquisa, Processo Seletivo 1º/2027, Mestrado.

Programa: Tecnologias da Inteligência e Design Digital (TIDD), PUC-SP.

Estrutura: segue o roteiro de projeto do programa (SANTAELLA, [s.d.]).

Área de concentração: Processos Cognitivos e Ambientes Digitais.

Linha de pesquisa: 4. Inteligência Artificial e Gestão, com aderência secundária à linha 3, Interação Humano-Computador e Computação Social.

> **Aviso de uso responsável.** Detecção visual automatizada baseada em imagem, sujeita a erros e não equivalente a validação operacional, legal, de segurança ou aeronáutica. Esta pesquisa avalia detectores, não locais: ela não produz, nem pretende produzir, qualquer validação de helipontos para uso, pouso, entrega ou conformidade regulatória.

Resumo

Detectores de objetos treinados com poucos exemplos costumam ser avaliados em um conjunto de validação pequeno, anotado pela própria equipe, e essas métricas, isoladamente, não caracterizam o comportamento em uma região real sem anotação. No caso estudado, o Helipad Detector, quatro experimentos com mAP@50 de 0,993 a 0,994 produziram, nos mesmos 7.767 pares região × tile de campo, taxas de detecção de 9,6% a 21,0%. A dissertação pergunta quanto dessa diferença se explica por linhagem de dados, validação e artefatos, e qual é a precisão das detecções segundo revisão humana amostral. Propõe um protocolo reprodutível com auditoria de linhagem, comparação controlada com partição espacial e estimativa de precisão por revisão humana, tratada como ato de interpretação de imagens, e não como verdade de campo. Um estudo sobre a confiança de quem revisa fica como extensão condicionada ao prazo e à aprovação ética.

Palavras-chave: detecção de objetos; avaliação de modelos; referência visual humana; interpretação de imagens; confiança em automação; imagens de satélite.

1. Questão da pesquisa

1.1 Contexto e problema

O Helipad Detector é um projeto desenvolvido em equipe, com repositório público e registro das contribuições de cada autor (MINDFUL AI RESEARCH, 2026a). Utiliza redes YOLO treinadas para uma única classe (“heliponto”), aplicadas a recortes de imagens de satélite (tiles de 256 × 256 pixels, zoom 19), com avaliação de campo em dez regiões da Grande São Paulo, recorte que a pesquisa mantém.

O projeto teve origem como trabalho da disciplina Redes Neurais, do 5º semestre da graduação em Ciência de Dados e Inteligência Artificial da PUC-SP, ministrada pelo Prof. Rooney Ribeiro Albuquerque Coelho. A proponente integra o projeto desde junho de 2026. A contribuição que sustenta esta pesquisa é a automação da coleta e da geocodificação de tiles, a execução dos experimentos exp2, exp3 e exp4 e a avaliação de campo nas dez regiões, ampliada a partir da região explorada por Pedro Vyctor Almeida, autor do conjunto anotado original e do exp1. As demais entregas do projeto (dashboard interativo, apresentação e relatórios em português e inglês) estão no repositório Helipad Detector e não fazem parte desta pesquisa (MINDFUL AI RESEARCH, 2026b, 2026c, 2026d, 2026e).

Verdade de campo é a confirmação independente, no local ou por fonte oficial, do que existe no ponto detectado. **Referência visual humana** é o rótulo que pessoas atribuem a partir das mesmas imagens: um ato de interpretação, sujeito a ambiguidade, e não equivalente à verdade de campo. O projeto não dispõe da primeira em escala.

Os experimentos com YOLOv8n e YOLO11n são praticamente indistinguíveis na validação (mAP@50 de 0,993 a 0,994; Tabela 1). Nos mesmos 7.767 pares região × *tile* (5.540 tiles distintos) de dez regiões, com limiar de confiança de 0,25, produzem taxas de detecção de 9,64% a 21,00% (Tabela 2 e Figura 1): a maior é mais que o dobro da menor.

Tabela 1. Desempenho no conjunto de validação (melhor época por mAP@50–95)

Exp.	Modelo (épocas)	Dados (treino / val.)	Melhor época	Prec.	Rev.	mAP@50	mAP@50–95 melhor (última)
exp1	YOLOv8n (60)	Project-2 (178 / 34)†	54	1,000	0,963	0,994	0,881 (0,841)
exp2	YOLOv8n (100)	Project-2 (178 / 34)	81	0,982	0,971	0,993	0,888 (0,841)
exp3	YOLOv8n (100)	Project-1, com aumento§ (356 / 34)	78	0,943	1,000	0,993	0,885 (0,841)
exp4	YOLO11n (100)	Project-2 (178 / 34)‡	54	0,970	0,948	0,993	0,877 (0,854)

Fonte: results.csv e args.yaml dos experimentos, no repositório; semente 42 e imagens de 640 px em todos. †Atribuição por evidência documental, não por registro de contagem: o args.yaml e os pesos preservados do exp1 (execução "exp1-2", de Pedro Vyctor Almeida) apontam para a versão 2 do conjunto e são idênticos, byte a byte, aos da cópia da proponente; o registro de treino salvo no notebook (116 imagens de treino e 33 de validação) é compatível com a execução original do exp1, na versão 1, da qual só resta o args.yaml. Indício forte, a confirmar na Etapa 1. ‡Mesmos dados do exp2, mas Ultralytics 8.4.163 (exp2: 8.4.98), que sinalizou como corrompidos três arquivos de rótulo do treino que misturam polígonos e caixas. §Bifurcação do conjunto com aumento de dados (rotação de ±15°, brilho e inversões).

Por isso, atualmente, nenhuma comparação entre os experimentos do repositório constitui um experimento controlado; o par exp2 × exp4 é o mais próximo disso, com a ressalva da diferença de versão do Ultralytics e dos três arquivos de rótulo sinalizados.

Tabela 2. Detecção em campo (limiar de confiança 0,25; 7.767 pares região × *tile*, dez regiões)

Experimento	Tiles com detecção	Taxa	IC 95% de Wilson (ingênuo)
exp1	749	9,64%	9,01–10,32%
exp3	1.389	17,88%	17,05–18,75%
exp4	1.423	18,32%	17,48–19,20%
exp2 (reexecução)	1.631	21,00%	20,11–21,92%

Fonte: relatórios detection_summary_by_region*.json do repositório. A execução de produção do exp2 (7.943 tiles) detectou 1.677 (21,1%). O intervalo ingênuo trata os tiles como independentes e, por isso, subestima a incerteza, pois tiles vizinhos são espacialmente dependentes.

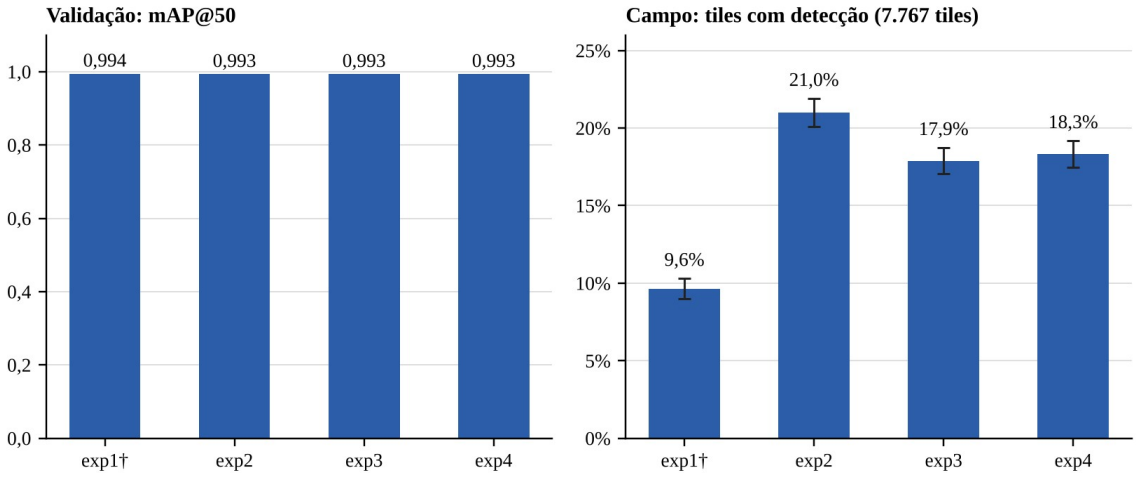


Figura 1. Mesma família de modelos, métricas de validação quase idênticas e taxas de detecção em campo muito diferentes. Barras de erro: intervalo de Wilson de 95% (ingênuo). †Versão de dados do exp1 atribuída por evidência documental (Tabela 1). Fonte: elaboração própria com dados do repositório.

A taxa de detecção é a fração de tiles com ao menos uma detecção; não é precisão nem revocação, e sem verdade de campo não se sabe se uma taxa maior significa mais helipontos encontrados ou mais falsos positivos. O projeto dispõe apenas de revisões caso a caso, selecionadas sem sorteio (na Faria Lima, por exemplo, três acertos, dois falsos positivos e um tile vazio, por falha de download, marcado como detecção). Logo, a precisão em campo e a parcela da taxa causada por tiles defeituosos são hoje desconhecidas e serão estimadas nas Etapas 1 e 3. Um mAP próximo de 1 não revela isso.

Há ainda risco de vazamento, já medido em parte. Comparando as imagens anotadas, pixel a pixel, com os *tiles* de campo reconstituídos a partir do repositório (5.540 *tiles* distintos, em 7.767 pares região × *tile*, pois regiões vizinhas se sobrepõem), 125 das 225 imagens com coordenada (87 de 177 no treino, 25 de 34 na validação e 13 de 14 no teste) são cópias de um *tile* de campo, o que corresponde a 2,3% dos *tiles* distintos. As 100 restantes não coincidem com nenhum *tile* de campo e ficam fora das caixas das dez regiões. O treino, portanto, já viu 87 *tiles* do campo, e a taxa de detecção nesses *tiles* tende a ser inflada; o efeito global não pode ser quantificado sem as detecções por *tile*. Não há cópia direta entre validação ou teste e treino, mas 15 das 34 imagens de validação e 3 das 14 de teste estão a até um *tile* (cerca de 70 m) de uma imagem de treino, vizinhança que será tratada como risco, e não como vazamento confirmado.

1.2 Pergunta central e perguntas derivadas

Pergunta central. Quanto da diferença de detecção em campo entre detectores YOLO treinados com poucos exemplos se explica por linhagem de dados, escolhas de validação e artefatos de dados, e qual é a precisão dessas detecções segundo revisão humana amostral?

Perguntas derivadas.

- **QE1 (auditoria de linhagem).** Quanto das diferenças em campo decorre da linhagem dos dados (versão, partição, sobreposição com o campo, *tiles* defeituosos) e quanto da arquitetura?
- **QE2 (comparação controlada e partição espacial).** Quanto a seleção da melhor época no próprio conjunto de validação e a partição aleatória superestimam o desempenho em regiões novas?
- **QE3 (revisão humana amostral).** Qual é a precisão em campo, por faixa de confiança e por região, segundo a referência visual humana, e quão confiável é essa referência (concordância e proporção de “incerto”)?

A influência da apresentação da confiança sobre a decisão de revisores (QE4, exploratória) é uma extensão condicionada ao prazo e à aprovação ética (seção 7).

2. Estado da arte

Detecção em imagens aéreas. A detecção de objetos em sensoriamento remoto é revisada por Cheng e Han (2016) e conta com grandes conjuntos, como o DOTA (XIA et al., 2018; DING et al., 2022). A família YOLO (REDMON et al., 2016; ULTRALYTICS, 2026), com pré-treino no COCO (LIN et al., 2014), é a base dos modelos usados, e Padilla et al. (2021) mostram que o mAP depende de convenções de implementação que precisam ser declaradas. Esses trabalhos tratam de grandes conjuntos anotados, não de confiar em um detector treinado com poucos exemplos em uma região sem anotação.

Detecção de helipontos. A detecção de helipontos em imagens aéreas e de satélite já foi estudada. Bitoun e Winkler (2020) apresentam o HelipadCat, conjunto de cerca de 6.000 imagens em 12 categorias, construído a partir da base de dados da FAA, e um método de detecção com Mask R-CNN, filtros por área e sombra e geração de marcadores em mapa. Specht et al. (2021) treinam redes convolucionais (ResNet101, Inception-V3, Xception e EfficientNet-b0) para classificar imagens de satélite como heliponto ou não, em uma base de 9.324 imagens, e relatam cerca de 95% de acurácia de validação com a EfficientNet-b0; os autores também registram imprecisões na base 5010 da FAA. Suprapto et al. (2021) usam Tiny YOLO para detectar helipontos em câmera embarcada, voltados ao pouso de drones, tarefa distinta da desta pesquisa. Esses trabalhos mostram que detectar helipontos não é, por si, a contribuição aqui, e seus resultados não são comparáveis aos desta pesquisa: acurácia de classificação e detecção em câmera embarcada não equivalem a mAP ou precisão de detecção em imagens de satélite. A pesquisa se delimita pela avaliação do detector em região sem anotação, com partição espacial e revisão humana amostral.

Validade da avaliação. Kaufman et al. (2012) formalizam o vazamento de dados. Roberts et al. (2017) e Ploton et al. (2020) mostram, para dados espaciais, que a validação que respeita a estrutura espacial revela desempenho pior que o aparente; esses resultados vêm da ecologia, e sua transferência para detectores em imagens de satélite é uma hipótese a testar (H2). Dietterich (1998) trata de testes para comparar modelos, e Brown, Cai e DasGupta (2001), de intervalos para proporções, base dos intervalos de Wilson usados na Tabela 2.

Calibração. Guo et al. (2017) mostram que redes modernas tendem a ser mal calibradas, em classificação de imagens; a calibração de detectores com poucos dados será investigada a partir da precisão por faixa de confiança (Etapa 3), pois a confiança é o principal sinal que quem revisa recebe.

Interpretação de imagens e cognição. Na semiótica da imagem, ver não é registrar um fato, e sim interpretar um signo, e a interpretação depende de convenções, repertório e contexto (SANTAELLA; NÖTH, 1998). Uma imagem de satélite é uma representação feita por um sensor, em data e resolução determinadas, e usá-la para afirmar o que existe no solo exige inferência. A cognição distribuída (HUTCHINS, 1995) descreve o raciocínio como um processo que se estende por pessoas, instrumentos e procedimentos. Ambas sustentam tratar a revisão de detecções como atividade cognitiva situada em um ambiente digital, e não como leitura neutra de um gabarito.

Confiança em automação e transparência. Parasuraman e Riley (1997) distinguem uso, mau uso, desuso e abuso da automação; Lee e See (2004) tratam da confiança apropriada; Amershi et al. (2019) propõem diretrizes de interação humano-IA. *Model Cards* (MITCHELL et al., 2019) e *Datasheets for Datasets* (GEBRU et al., 2021) propõem relatar usos pretendidos e limites, prática que o projeto adota.

Lacuna. Na revisão preliminar, restrita às fontes já consultadas, não foi identificado trabalho que combine, para um objeto urbano raro em imagens de satélite, comparações controladas, validação espacial e estimativa de precisão por revisão humana amostral que trate a referência humana como interpretação, com concordância e incerteza declaradas. A busca foi exploratória na web, com

combinações dos termos “helipad detection”, “satellite imagery”, “aerial images”, “deep learning” e “YOLO”, e não teve caráter sistemático ou exaustivo. A revisão sistemática (Etapa 1) poderá alterar essa conclusão.

3. Justificativas

Teórica e prática. Os trabalhos revistos tratam, em separado, de métricas, validade da avaliação, calibração e confiança em automação. Este caso os reúne em um problema concreto e mostra uma lacuna entre métrica de validação e comportamento em campo que não se resolve com mais treino. O protocolo resultante (auditoria de linhagem, partição espacial, revisão humana amostral e registro de auditoria) pode ser reaplicado a outros detectores e regiões e transforma uma taxa de detecção sem interpretação em estimativas com incerteza explícita.

Aderência ao TIDD. O objeto desta pesquisa, na área Processos Cognitivos e Ambientes Digitais, não é o detector em si, e sim a produção de evidência sobre ele em um ambiente digital: pessoas olham imagens de satélite em uma interface, atribuem rótulos (heliponto, não heliponto, incerto) e, com eles, decidem se confiam no sistema. Dois fenômenos cognitivos estão em jogo. Primeiro, a referência visual humana é um ato de interpretação: depende do repertório de quem revisa e da resolução e da data da imagem, e gera discordância e hesitação que precisam ser medidas, não eliminadas. Segundo, a confiança do revisor no detector é um fenômeno de interação humano-automação (PARASURAMAN; RILEY, 1997; LEE; SEE, 2004), influenciado pelo que a interface mostra (AMERSHI et al., 2019). A aderência também está nas ementas do programa: a área de concentração trata da “modelagem de performances cognitivas: percepção, atenção, inferência”, e a linha 4 descreve a passagem para “um mundo de máquinas probabilísticas, implicando lógicas e riscos distintos”, com atenção aos impactos éticos e sociais da IA. Um detector cuja confiança é lida por pessoas é um caso concreto desse mundo. Por isso, a pesquisa se inscreve na linha 4, pela evidência produzida sobre uma máquina probabilística e pelos limites da automação, e, secundariamente, na linha 3, pela interação das pessoas com sistemas de IA e pela governança.

Social e ética. Um detector de helipontos pode ser mal interpretado como evidência de que um local é seguro, operacional ou autorizado. Nada disso é verdade. Todas as saídas serão tratadas como analíticas e não autoritativas, com o aviso do início deste documento.

4. Objetivos

Objetivo geral. Propor e testar um protocolo reprodutível de avaliação de detectores visuais de helipontos em imagens de satélite sem verdade de campo em escala, tratando a revisão humana como referência interpretativa, com incerteza e concordância declaradas.

Objetivos específicos.

1. Reconstituir a linhagem dos dados e das configurações dos experimentos existentes, verificando a sobreposição entre treino e campo e os *tiles* defeituosos (QE1).
2. Realizar comparações controladas entre YOLOv8n e YOLO11n e quantificar o viés otimista da seleção da melhor época e da partição aleatória, frente a uma partição espacial por região (QE1 e QE2).
3. Estimar a precisão em campo, por faixa de confiança e por região, por revisão humana amostral cega, feita por dois revisores (a proponente e Pedro Vyctor Almeida), relatando a concordância entre revisores e o tratamento de “incerto” (QE3).
4. Documentar sistema e dados com *Model Card*, *Data Card* e protocolo de revisão auditável.

Resultados esperados. Relatório de linhagem; estimativas de desempenho com intervalos de incerteza, por partição e por região; estimativa de precisão por revisão humana amostral; *Model Card*, *Data Card* e protocolo de revisão; ao menos um artigo. Não se espera, nem se afirmará, validação operacional, legal ou aeronáutica de nenhum local detectado.

5. Hipóteses

Hipótese	Teste	Refutação
H1. Com mAP praticamente igual na validação, a taxa de detecção em campo varia mais entre versões e artefatos de dados (como *tiles* vazios) do que entre arquiteturas treinadas nos mesmos dados.	Etapas 1 e 2	A diferença entre arquiteturas, com dados idênticos e várias sementes, é maior que a diferença entre versões de dados.
H2. A seleção da melhor época no mesmo conjunto de validação e a partição aleatória superestimam o desempenho; em partição espacial, as métricas caem de forma mensurável.	Etapa 2	A diferença entre partição aleatória e espacial fica dentro do intervalo de incerteza (*bootstrap*).
H3. A precisão em campo, estimada por revisão humana, é menor que a de validação; a variação entre regiões será apenas descrita.	Etapa 3	O intervalo de 95% da precisão em campo é compatível com a de validação. Com cerca de 30 itens por região, as diferenças entre regiões não serão testadas, só descritas.

Extensão (H4, exploratória). Mostrar confiança calibrada e exemplos de erros típicos reduz a aceitação de falsos positivos por revisores, frente a mostrar só a caixa e a confiança bruta. Seu tamanho esperado não permitirá inferência forte.

6. Fundamentação teórica

A pesquisa se apoia em quatro eixos, escolhidos por decorrerem da lacuna entre métrica de validação e comportamento em campo. O primeiro é a **detecção como predição probabilística**, resumida por precisão, revocação e mAP (LIN et al., 2014; PADILLA et al., 2021). O segundo é a **validade da avaliação**: vazamento (KAUFMAN et al., 2012), dependência espacial (ROBERTS et al., 2017; PLOTON et al., 2020) e seleção de modelo no próprio conjunto de relato são fontes de otimismo. O terceiro é a **interpretação de imagens e a noção de evidência** (6.1). O quarto é a **confiança, a incerteza e a IA responsável**: calibração (GUO et al., 2017), confiança apropriada (PARASURAMAN; RILEY, 1997; LEE; SEE, 2004; AMERSHI et al., 2019), transparência (MITCHELL et al., 2019; GEBRU et al., 2021) e proteção de dados pessoais (BRASIL, 2018), pois imagens de telhados podem permitir inferências sobre pessoas e edificações.

6.1 Evidência quando não há verdade de campo

Interpretar uma imagem é um ato situado: o mesmo recorte pode ser lido de modos diferentes conforme o repertório de quem olha e a resolução e a data da imagem (SANTAELLA; NÖTH, 1998), e o julgamento do revisor se forma em um sistema que inclui interface, guia de critérios e saída do modelo (HUTCHINS, 1995). Por isso, o rótulo humano não é tratado como gabarito. **Evidência**, aqui, é toda afirmação sobre o desempenho do detector em campo que traga procedência rastreável (linhagem), procedimento reproduzível, incerteza declarada e indicação do nível em que se situa (Tabela 3). Afirmação sem nível declarado não é evidência. A discordância entre revisores e a categoria “incerto” são dados do estudo, não ruído a descartar.

Tabela 3. Níveis de evidência adotados na pesquisa

Nível	O que é	O que permite afirmar	O que não permite afirmar
1. Métrica de validação	Precisão, revocação e mAP no conjunto anotado pela equipe.	Desempenho no conjunto pequeno de validação.	Desempenho em regiões não anotadas.
2. Taxa de detecção em campo	Fração de *tiles* com ao menos uma detecção.	Comparar detectores nos mesmos *tiles*.	Precisão, revocação ou número de helipontos.
3. Referência visual humana amostral	Rótulos de dois revisores em amostra estratificada, com concordância e "incerto".	Estimar a precisão por estrato, com incerteza explícita.	Verdade de campo; revocação em larga escala.
4. Verdade de campo	Confirmação independente, no local ou por fonte oficial.	Fora do escopo.	Não será produzida nem afirmada.

7. Metodologia

Tipo de pesquisa. Aplicada e empírica, predominantemente quantitativa (experimentos computacionais e estimação estatística), com um componente interpretativo: a revisão humana como produção de referência visual.

Material de partida e autorização. O repositório 3-project-ai-ml-yolo-helipad_detector, da organização Mindful-AI-Research, criada pela proponente, é público e reúne os experimentos exp1 a exp4, os relatórios de campo e a documentação. O uso do repositório e dos dados nesta pesquisa conta com a autorização de Pedro Vyctor Almeida, coautor do conjunto anotado original, registrada em termo de autorização **assinado por Pedro Vyctor Almeida e pela proponente**. Os dados são pequenos (226 imagens na versão 2: 178 de treino, 34 de validação e 14 de teste), com imagens de um único provedor e data. Os termos de uso do provedor para conjuntos derivados e redistribuição serão verificados na Etapa 1, antes de qualquer publicação de dados. A apresentação do projeto **resume o trabalho e o método.**

Tabela 4. Dependências e planos alternativos

Dependência	Risco	Plano B
Versão de dados do exp1	Sem registro de contagem que corresponda às métricas preservadas; atribuição à versão 2 por evidência documental.	Se a Etapa 1 não a confirmar, o exp1 sai das comparações e fica só como observação descritiva; QE1 e QE2 não dependem dele (a Etapa 2 retreina).
Rótulos sinalizados no exp4	Três arquivos de rótulo do treino misturam polígonos e caixas; o Ultralytics 8.4.163 os sinaliza como corrompidos.	A Etapa 1 padroniza os rótulos; a Etapa 2 retreina os dois modelos na mesma versão, com dados verificados; se inviável, exp2 × exp4 sai com ressalva.
Autorização de uso	Pedro Vyctor Almeida retirar a autorização assinada, ou os termos do provedor (Esri World Imagery, terceiro) restringirem o uso ou a redistribuição das imagens e do conjunto derivado.	Restringir ao material de autoria da proponente (coleta, geocodificação, exp2 a exp4, relatórios de campo), reanotando o necessário.
Segundo revisor	Pedro Vyctor Almeida aceitou (termo assinado); o risco é a indisponibilidade ao longo do projeto.	Convidar substituto de mesmo perfil; sem ele, relatar com um só revisor e declarar a limitação.

Etapa 1. Auditoria de linhagem e reprodutibilidade. Reconstituir, para cada experimento, a versão dos dados, a partição, a configuração e a semente, confirmando a versão de dados do exp1, padronizando os rótulos (a maioria dos arquivos contém polígonos, que o treino de detecção converte em caixas; três misturam polígonos e caixas) e verificando o efeito da versão do Ultralytics. Estender o cruzamento treino × campo já feito (cópias de *tile* e vizinhança) aos *tiles* faltantes da Faria Lima e às detecções por *tile* de cada experimento para medir a sobreposição, medir a fração de *tiles* vazios ou corrompidos enviados à inferência e fixar versões de dados, código e dependências. Em paralelo, fazer a revisão sistemática da literatura, incluindo semiótica da imagem e cognição.

Etapa 2. Comparações controladas e partição espacial. Treinar YOLOv8n e YOLO11n com os mesmos dados, a mesma partição e as mesmas épocas, com ao menos três sementes, e comparar com testes para modelos pareados, como McNemar e validação cruzada 5×2 (DIETTERICH, 1998), e intervalos de Wilson (BROWN; CAI; DASGUPTA, 2001). Depois, treinar e avaliar com partição por região (deixando uma de fora a cada rodada, quando viável), comparar com a partição aleatória e quantificar a diferença. Como regiões vizinhas compartilham tiles (5.540 distintos em 7.767 pares), a partição será feita sobre tiles distintos, retirando do treino os tiles compartilhados com a região deixada de fora. A Baixada Santista é candidata a região de reserva, desde que sua ausência do treino seja confirmada por coordenadas; a Faria Lima só serve se forem excluídas as duas imagens de treino que já coincidem com seus tiles. A época será escolhida em conjunto separado do usado para reportar.

Etapa 3. Revisão humana amostral em campo. Sortear, de forma estratificada por faixa de confiança e por região, detecções do(s) modelo(s) da Etapa 2 sobre os 7.767 pares região × *tile* comuns, mais uma amostra de *tiles* sem detecção para estimar omissões, e produzir a referência visual humana conforme a Tabela 5, com dois revisores: a proponente, Fabiana Rotella Campaner, e Pedro Vyctor Almeida. A precisão por estrato é estimada com intervalos de Wilson e *bootstrap* por blocos espaciais; o limiar de confiança é variado para mostrar como mudam precisão e cobertura, e a precisão por faixa alimenta o diagrama de confiabilidade (GUO et al., 2017). O resultado é referência visual humana, e não verdade de campo.

Tabela 5. Protocolo de revisão humana (Etapa 3)

Item	Definição
Revisores	Dois: a proponente e Pedro Vyctor Almeida, que aceitou participar. Ele anotou o conjunto original e treinou o exp1, portanto não é independente do projeto; a limitação é declarada e, se houver disponibilidade, uma subamostra será revisada por uma pessoa externa à equipe.
Independência e cegueira	Cada revisor trabalha sozinho. A fila é gerada por script com semente fixa, em ordem aleatória, misturando detecções e *tiles* sem detecção; os revisores não veem a confiança, o experimento de origem nem o estrato. Como ambos conhecem o detector, e o segundo revisor anotou os dados de treino (seus critérios podem coincidir com os do rótulo de treino), a análise principal é repetida com cada revisor separadamente (sensibilidade).
Categorias e piloto	Heliponto, não heliponto e incerto, com critérios visuais em guia escrito. Piloto de cerca de 50 itens para ajustar guia e amostra e calcular a concordância (kappa de Cohen).
Amostra (ordem de grandeza)	Três faixas de confiança (0,25–0,50; 0,50–0,75; ≥ 0,75), com cerca de 100 detecções por faixa, sorteadas com cota mínima por região; estratos com menos de cerca de 100 são revisados por completo. Mais cerca de 100 *tiles* sem detecção. Total da ordem de 400 itens por revisor, a ajustar pelo piloto.
Poder para estratos raros	Com n ≈ 100 por faixa, a meia-largura do intervalo de Wilson é de cerca de ±10 pontos percentuais (p = 0,5), e comparar duas faixas tem poder de cerca de 80% para diferenças de 20 pontos (50% contra 70%). Por região (n ≈ 30), a meia-largura chega a ±17 pontos, e os resultados são descritivos. Com poucos positivos esperados, relata-se só o limite superior (regra dos três: zero em 100 implica cerca de 3%). Como a dependência espacial alarga os intervalos, usa-se *bootstrap* por blocos.
“Incerto” e desacordos	“Incerto” é categoria própria, nunca fundida em silêncio: a precisão é relatada com “incerto” como não heliponto, como heliponto e excluído, junto com sua proporção por estrato. O kappa é calculado antes de qualquer resolução; desacordos são discutidos em sessão registrada e, se persistirem, o item fica “incerto”.

Etapa 4. Documentação e auditoria. Produzir *Model Card*, *Data Card*, protocolo de revisão e esquema de registro de auditoria, com artefatos versionados.

Extensão condicionada (H4, QE4). Comparar duas interfaces (caixa e confiança bruta *versus* confiança calibrada com exemplos de erros típicos), medindo aceitação de falsos positivos e tempo de decisão. Exige aprovação ética: o projeto será submetido no semestre 2 e a extensão só será executada se a aprovação sair antes do semestre 4 e houver prazo; do contrário, fica como trabalho

futuro, sem prejuízo do escopo central. Os métodos de desenho e análise desse estudo serão aprofundados em disciplina de interação humano-computador (seção 8) e na bibliografia a consultar.

Ética, privacidade e limitações. Nenhuma publicação identificará pessoas ou edificações específicas, e os resultados serão agregados por região; a necessidade de tratar dados pessoais será avaliada à luz da LGPD (BRASIL, 2018). Limitações previstas: conjunto pequeno e geograficamente heterogêneo; um único provedor (Esri World Imagery) e data de imagem; ausência de verdade de campo em escala; custo da revisão humana; ambiguidade da interpretação visual; e poder limitado em estratos raros.

8. Cronograma (24 meses, dentro dos 18 a 30 do programa)

Semestre	Atividades	Entregas
1 (meses 1–6)	Disciplinas: Epistemologia e Metodologia da Pesquisa (EMP, obrigatória) e Fundamentos da Inteligência Artificial (FIA, linha 4, módulo 1); proficiência em língua estrangeira, em até 6 meses do ingresso (edital, item 6.4); revisão sistemática; Etapa 1; desenho do protocolo de revisão.	Relatório de linhagem; protocolo de revisão (v1)
2 (meses 7–12)	Disciplinas: duas optativas, candidatas Interação Humano-Computador e Experiência do Usuário (linha 3) e Teoria dos Signos, Símbolos e Códigos (linha 4); Etapa 2; piloto da revisão; submissão ao comitê de ética (extensão).	Resultados de QE1 e QE2; relatório do piloto
3 (meses 13–18)	Exame de qualificação (semestre 3); Etapa 3; decisão sobre a extensão, com a aprovação ética em mãos.	Texto de qualificação; resultados de QE3
4 (meses 19–24)	Etapa 4; extensão com revisores, se aprovada e houver prazo; redação; artigo; defesa.	Dissertação; ao menos um artigo submetido

O mestrado do TIDD dura de 18 a 30 meses (página do programa); propõem-se 24. As disciplinas candidatas dependem da oferta, pois o programa informa que a ementa de cada uma recebe, a cada semestre, uma especificação de conteúdo; a qualificação segue o regulamento do programa.

Bibliografia preliminar

Lista preliminar, nas normas da ABNT, das obras consultadas para a elaboração deste projeto, seguida das obras a consultar. Será complementada durante a revisão sistemática da literatura.

AMERSHI, S. et al. Guidelines for human-AI interaction. *In*: PROCEEDINGS OF THE 2019 CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2019, Glasgow. New York: ACM, 2019. p. 1–13.

BITOUN, J.; WINKLER, S. HelipadCat: categorised helipad image dataset and detection method. In: IEEE REGION 10 CONFERENCE (TENCON), 2020, Osaka. *Proceedings* [...]. [S. l.]: IEEE, 2020.

BRASIL. *Lei nº 13.709, de 14 de agosto de 2018*. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 13 out. 2026.

BROWN, L. D.; CAI, T. T.; DASGUPTA, A. Interval estimation for a binomial proportion. *Statistical Science*, v. 16, n. 2, p. 101–133, 2001. DOI 10.1214/ss/1009213286.

CHENG, G.; HAN, J. A survey on object detection in optical remote sensing images. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 117, p. 11–28, 2016.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, v. 10, n. 7, p. 1895–1923, 1998.

DING, J. et al. Object detection in aerial images: a large-scale benchmark and challenges. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 44, n. 11, p. 7778–7796, 2022.

GEBRU, T. et al. Datasheets for datasets. *Communications of the ACM*, v. 64, n. 12, p. 86–92, 2021.

GUO, C. et al. On calibration of modern neural networks. *In*: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 34., 2017, Sydney. [S. l.]: PMLR, 2017. *Proceedings of Machine Learning Research*, v. 70, p. 1321–1330, 2017.

HUTCHINS, E. *Cognition in the wild*. Cambridge, MA: MIT Press, 1995.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, v. 6, n. 4, art. 15, 2012.

LEE, J. D.; SEE, K. A. Trust in automation: designing for appropriate reliance. *Human Factors*, v. 46, n. 1, p. 50–80, 2004.

LIN, T.-Y. et al. *Microsoft COCO: common objects in context*. arXiv:1405.0312, 2014. Disponível em: https://arxiv.org/abs/1405.0312. Acesso em: 13 out. 2026.

MINDFUL AI RESEARCH. Helipad Detector: 3-project-ai-ml-yolo-helipad_detector. Repositório. GitHub, 2026a. Disponível em: https://github.com/Mindful-AI-Research/3-project-ai-ml-yolo-helipad_detector. Acesso em: 13 out. 2026.

MINDFUL AI RESEARCH. Dashboard bilíngue: Streamlit. Material do projeto Helipad Detector. 2026b. Disponível em: https://helipad-detector-sp.streamlit.app/. Acesso em: 13 out. 2026.

MINDFUL AI RESEARCH. Full Data Analysis Report: English. Material do projeto Helipad Detector. 2026c. Disponível em: https://github.com/Mindful-AI-Research/3-project-ai-ml-yolo-helipad_detector/blob/db052a43d2b02254237735716dc841a3611d9e98/reports/helipad_detector_full_report/%F0%9F%87%AC%F0%9F%87%A7Helipad_Detector_Full_Report.pdf. Acesso em: 13 out. 2026.

MINDFUL AI RESEARCH. Relatório completo de análise de dados: Português. Material do projeto Helipad Detector. 2026d. Disponível em: https://github.com/Mindful-AI-Research/3-project-ai-ml-yolo-helipad_detector/blob/3849b944fbfbf2df224fbd7e636751872c35258a/reports/helipad_detector_full_report/%F0%9F%87%A7%F0%9F%87%B7Helipad_Detector_Relatorio_Completo.pdf. Acesso em: 13 out. 2026.

MINDFUL AI RESEARCH. Apresentação do projeto Helipad Detector. Material do projeto Helipad Detector. 2026e. Disponível em: https://timely-brioche-b6c92f.netlify.app/. Acesso em: 13 out. 2026.

MITCHELL, M. et al. Model cards for model reporting. *In*: PROCEEDINGS OF THE CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY, 2019, Atlanta. New York: ACM, 2019. p. 220–229.

PADILLA, R. et al. A comparative analysis of object detection metrics with a companion open-source toolkit. *Electronics*, v. 10, n. 3, art. 279, 2021.

PARASURAMAN, R.; RILEY, V. Humans and automation: use, misuse, disuse, abuse. *Human Factors*, v. 39, n. 2, p. 230–253, 1997.

PLOTON, P. et al. Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nature Communications*, v. 11, art. 4540, 2020. DOI 10.1038/s41467-020-18321-y.

REDMON, J. et al. You only look once: unified, real-time object detection. *In*: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016, Las Vegas. [S. l.]: IEEE, 2016. p. 779–788.

ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, v. 40, n. 8, p. 913–929, 2017.

SANTAELLA, L. *Roteiro de projeto*. São Paulo: PEPG em Tecnologias da Inteligência e Design Digital, PUC-SP, [s.d.]. Disponível em: https://www.pucsp.br/pos-graduacao/mestrado-e-doutorado/tecnologias-da-inteligencia-e-design-digital. Acesso em: 13 out. 2026.

SANTAELLA, L.; NÖTH, W. *Imagem*: cognição, semiótica, mídia. São Paulo: Iluminuras, 1998.

SPECHT, D.; RASOOL, G.; BOUAYNAYA, N.; JOHNSON, C. Intelligent helipad detection from satellite imagery. In: VERTICAL FLIGHT SOCIETY ANNUAL FORUM AND TECHNOLOGY DISPLAY, 77., 2021, on-line. *Proceedings* [...]. [S. l.]: Vertical Flight Society, 2021. DOI 10.4050/F-0077-2021-16856.

SUPRAPTO, B. Y. et al. The detection system of helipad for unmanned aerial vehicle landing using YOLO algorithm. *Jurnal Ilmiah Teknik Elektro Komputer dan Informatika* (JITEKI), v. 7, n. 2, p. 193–206, 2021. DOI 10.26555/jiteki.v7i2.20684.

ULTRALYTICS. *Ultralytics YOLO*. Software. [S. l.]: Ultralytics, 2026. Disponível em: https://github.com/ultralytics/ultralytics. Acesso em: 13 out. 2026.

XIA, G.-S. et al. DOTA: a large-scale dataset for object detection in aerial images. *In*: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2018, Salt Lake City. [S. l.]: IEEE, 2018. p. 3974–3983.

Obras a consultar (bibliografia das disciplinas do programa, página do TIDD; ainda não consultadas para este projeto):

CHALMERS, A. F. *O que é ciência, afinal?* São Paulo: Brasiliense, 1993.

LAZAR, J.; FENG, J.; HOCHHEISER, H. *Research methods in human-computer interaction*. 2. ed. Cambridge, MA: Morgan Kaufmann, 2017.

RUSSELL, S.; NORVIG, P. *Inteligência artificial*. 3. ed. Rio de Janeiro: Elsevier, 2013.

SANTAELLA, L. *Comunicação & pesquisa*. 2. ed. São Paulo: Hacker; Bluecom, 2010.

SANTAELLA, L.; VIEIRA, J. A. *Metaciência*. São Paulo: Mérito, 2008.